

## Zufällige Abbildungen und Faktorisieren via Pollard-Rho

Felix Potthast

02.03.2016



- Arithmetische, deterministische Methoden zur Generierung zufällig wirkender Folgen
- Verwendung z.B. für Monte-Carlo Verfahren oder Kryptographie
- Übliche Form:  $x_{i+1} = f(x_i)$  mit Seed  $x_0$ ,  $x_i \in \{0, \dots, m-1\} = \mathbb{Z}/m\mathbb{Z}$
- Gewünschte Eigenschaften: lange Periode, Gleichverteilung

## Definition: Periodische Folge

Sei  $(x_i)_{i \geq 0}$  eine Folge.  $x_i$  ist periodisch mit der Periodenlänge  $\lambda$  und der Vorperiodenlänge  $\mu$  (und  $\rho = \mu + \lambda$ ), wenn gilt:

$x_0, x_1, \dots, x_\mu, \dots, x_{\mu+\lambda-1}$  sind paarweise verschieden, für  $n \geq \mu$  gilt aber:  $x_{n+\lambda} = x_n$

Sei  $f : \mathbb{Z}/m\mathbb{Z} \rightarrow \mathbb{Z}/m\mathbb{Z}$  beliebig.

Dann ist die Folge  $(x_i)_{i \geq 0}$ ,  $x_0 \in \mathbb{Z}/m\mathbb{Z}$ ,  $x_{i+1} = f(x_i)$  periodisch mit  $1 \leq \lambda \leq m$  und  $0 \leq \mu$  sowie  $\mu + \lambda = \rho \leq m$ .

Es gibt  $m^m$  Abbildungen in obiger Form. Sei  $f$  nun eine daraus zufällig gewählte Abbildung. Dann ist die Wahrscheinlichkeit die gewünschte maximale Periodenlänge  $\lambda = m$  zu erhalten gegeben durch:  $\frac{(m-1)!}{m^m}$   
(Erläuterung:  $m!$  ist die Anzahl der Permutationen, der Zyklus bleibt aber gleich für  $m$  Verschiebungen)

Eine Approximation der Fakultät mit der Stirlingformel ergibt dann:

$$\frac{(m-1)!}{m^m} = \frac{m!}{m^{(m+1)}} \approx \frac{\sqrt{2\pi m} \left(\frac{m}{e}\right)^m}{m^{(m+1)}} = \sqrt{\frac{2\pi}{m}} \cdot \left(\frac{1}{e}\right)^m$$

Die Wahrscheinlichkeit, dass eine zufällig gewählte Abbildung  $f$  einen Zyklus der Länge 1 hat, ist gegeben durch:

$$1 - \left(\frac{m-1}{m}\right)^m = 1 - \left(1 - \frac{1}{m}\right)^m > 1 - \frac{1}{e} \approx 0.63$$

Sei  $f$  wieder eine zufällig gewählte Abbildung mit nun ebenfalls zufällig gewähltem Seed  $x_0$ . Die Wahrscheinlichkeit, eine Folge mit Vorperiodenlänge  $\mu$  und Periodenlänge  $\lambda$  zu erhalten, ist:

$$P_m(\mu, \lambda) = \frac{1}{m} \prod_{k=1}^{\mu+\lambda} \left(1 - \frac{k}{m}\right)$$

Erläuterung: Die ersten  $\mu + \lambda$  Werte müssen paarweise verschieden sein, danach muss ein bestimmter Wert erreicht werden, um  $\lambda$  zu erhalten. Der Durchschnitt für  $\mu + \lambda$  ist dann gegeben durch:

$$\sum_{\lambda=1}^m \sum_{\mu=0}^{m-\lambda} (\lambda + \mu) P_m(\mu, \lambda) = Q(m) \approx \sqrt{\frac{\pi m}{2}} \approx 1.253 \cdot \sqrt{m}$$

$Q(m)$  ist die Ramanujan  $Q$ -Funktion gegeben durch

$$Q(m) = \sum_{k=1}^m \frac{m!}{(m-k)!m^k}$$

Für  $k = o\left(m^{\frac{2}{3}}\right)$  und  $m \rightarrow \infty$  gilt:

$$\frac{m!}{(m-k)!m^k} = e^{\frac{-k^2}{2m}} \left( 1 + O\left(\frac{k}{m}\right) + O\left(\frac{k^3}{m^2}\right) \right)$$

Für alle  $k$ , mit  $m \rightarrow \infty$  gilt:

$$\frac{m!}{(m-k)!m^k} = e^{\frac{-k^2}{2m}} + O\left(\frac{1}{\sqrt{m}}\right)$$



Beweis:

$$\begin{aligned}\frac{m!}{(m-k)!m^k} &= \frac{\prod_{j=1}^{k-1} (m-j)}{m^k} = \prod_{j=1}^{k-1} \left(1 - \frac{j}{m}\right) = e^{\ln(\prod_{j=1}^{k-1} (1 - \frac{j}{m}))} \\ &= e^{\sum_{j=1}^{k-1} \ln(1 - \frac{j}{m})}\end{aligned}$$

Da  $k = o(n)$  wenden wir die Taylor-Formel auf den Logarithmus an:  
 $\ln(1+x) = x + O(x^2)$  mit  $x = \frac{-j}{m}$

$$e^{\sum_{j=1}^{k-1} \ln(1 - \frac{j}{m})} = e^{\sum_{j=1}^{k-1} \left(-\frac{j}{m} + O\left(\frac{j^2}{m^2}\right)\right)} = e^{\left(-\frac{k(k-1)}{2m} + O\left(\frac{k^3}{m^2}\right)\right)}$$

Dann können wir für den Fall  $k = o\left(m^{\frac{2}{3}}\right)$  die Taylor-Formel für die Exponentialfunktion anwenden:  $e^x = 1 + O(x)$

$$\begin{aligned} e^{\left(-\frac{k(k-1)}{2m} + O\left(\frac{k^3}{m^2}\right)\right)} &= e^{\left(\frac{-k^2}{2m} + \frac{k}{2m} + O\left(\frac{k^3}{m^2}\right)\right)} \\ &= e^{\left(\frac{-k^2}{2m}\right)} \cdot e^{\left(\frac{k}{2m} + O\left(\frac{k^3}{m^2}\right)\right)} = e^{\frac{-k^2}{2m}} \left(1 + O\left(\frac{k}{m}\right) + O\left(\frac{k^3}{m^2}\right)\right) \end{aligned}$$



Dann betrachten wir noch die Approximationsformel für alle  $k$ : Sei  $k_0 = m^{\frac{3}{5}}$ , dann gilt für  $k \leq k_0$  die obige Approximationsformel und wir setzen  $x = \frac{k}{\sqrt{2m}}$ :

$$\begin{aligned} e^{\frac{-k^2}{2m}} \left( 1 + O\left(\frac{k}{m}\right) + O\left(\frac{k^3}{m^2}\right) \right) &= e^{\frac{-k^2}{2m}} + e^{-x^2} O\left(\frac{k}{m}\right) + e^{-x^2} O\left(\frac{k^3}{m^2}\right) \\ &= e^{\frac{-k^2}{2m}} + e^{-x^2} O\left(\frac{x\sqrt{2m}}{m}\right) + e^{-x^2} O\left(\frac{(x\sqrt{2m})^3}{m^2}\right) \\ &= e^{\frac{-k^2}{2m}} + xe^{-x^2} O\left(\frac{1}{\sqrt{m}}\right) + x^3 e^{-x^2} O\left(\frac{1}{\sqrt{m}}\right) \end{aligned}$$

Es gilt:  $xe^{-x^2} = O(1)$  und  $x^3 e^{-x^2} = O(1)$  und daher:  $e^{\frac{-k^2}{2m}} + O\left(\frac{1}{\sqrt{m}}\right)$

Sei nun  $k \geq k_0$ , dann gilt:

$$\frac{m!}{(m - k_0)!m^{k_0}} \leq \frac{m!}{(m - k)!m^k}$$

und da  $k_0 = o\left(m^{\frac{2}{3}}\right)$ :

$$\begin{aligned} \frac{m!}{(m - k_0)!m^{k_0}} &= e^{\frac{-k_0^2}{2m}} + O\left(\frac{1}{\sqrt{m}}\right) = e^{\frac{-\sqrt[5]{m}}{2}} + O\left(\frac{1}{\sqrt{m}}\right) \\ \Rightarrow \frac{m!}{(m - k)!m^k} &= O\left(\frac{1}{\sqrt{m}}\right) \end{aligned}$$

Daraus lässt sich jetzt folgende Asymptotische Formel für  $Q(m)$  herleiten:

$$Q(m) = \sum_{k=1}^m \frac{m!}{(m-k)!m^k} = \sqrt{\frac{\pi m}{2}} + O(1)$$

Wir benutzen für unterschiedliche Bereiche der Summe unterschiedliche Fehlerabschätzungen: sei  $k_0 = o\left(m^{\frac{2}{3}}\right)$

$$\begin{aligned} Q(m) &= \sum_{k=1}^m \frac{m!}{(m-k)!m^k} = \sum_{k=1}^{k_0} \frac{m!}{(m-k)!m^k} + \sum_{k=k_0+1}^m \frac{m!}{(m-k)!m^k} \\ &= \sum_{k=1}^{k_0} e^{\frac{-k^2}{2m}} \left( 1 + O\left(\frac{k}{m}\right) + O\left(\frac{k^3}{m^2}\right) \right) + \Delta \end{aligned}$$

Wir betrachten dabei  $\Delta$  als vernachlässigbar, da exponentiell klein. Wir nehmen auch an, dass alle weiteren Terme vernachlässigbar sind und betrachten nun:  $\sum_{k=1}^{\infty} e^{\frac{-k^2}{2m}} + O(1)$ . Nach der Euler-Maclaurin Formel gilt:

$$\begin{aligned} \sum_{i=m}^n f(i) &= \int_m^n f(x) dx + \frac{f(n) + f(m)}{2} \\ &+ \sum_{j=1}^k \frac{B_{2j}}{(2j)!} \left( f^{(2j-1)}(n) - f^{(2j-1)}(m) \right) + R_{2k}(m, n) \end{aligned}$$

# Zufällige Abbildungen

Daraus folgt dann:

$$Q(m) = \sum_{k=1}^{\infty} e^{-\frac{k^2}{2m}} + O(1) = \int_0^{\infty} e^{-\frac{k^2}{2m}} dk + O(1)$$

Dann substituieren wir  $k = \varphi(x) = \frac{x}{\sqrt{m}}$ :

$$\sqrt{m} \int_0^{\infty} e^{-\frac{\left(\frac{k}{\sqrt{m}}\right)^2}{2m}} \left(\frac{1}{\sqrt{m}}\right) dx + O(1) = \sqrt{m} \int_{\varphi(0)}^{\varphi(\infty)} e^{-\frac{x^2}{2}} dx + O(1)$$

wobei

$$\int_0^{\infty} e^{-\frac{x^2}{2}} dx = \sqrt{\frac{\pi}{2}}$$

und daher insgesamt:

$$Q(m) = \sqrt{\frac{\pi}{2m}} + O(1)$$

Die Wahrscheinlichkeit, in einem Zyklus der Länge  $\lambda = 1$  zu enden, ist dann:

$$\sum_{\mu=0}^{m-1} P_m(\mu, 1) = \frac{1}{m} \sum_{k=1}^m \frac{m!}{(m-k)!m^k} \approx \frac{1}{m} \sqrt{\frac{\pi}{2 \cdot m}} \approx \frac{1.25}{m\sqrt{m}}$$



- Durchschnittliche Zyklenlänge relativ gering
- Für Zufallszahlengeneratoren sind hohe Zyklenlängen erwünscht
- Zufällige Zufallszahlengeneratoren sind daher nicht Optimal

Man vergleiche jeweils  $x_i$  mit  $x_{2i}$ , es werden also der Reihe nach größere Werte für  $\mu$  und  $\lambda$  getestet. Wenn  $x_k = x_{2k}$  gilt:  $\mu < i$  und  $\lambda$  ist ein Vielfaches von  $i$ . Dann kann man in einem weiteren Schritt die exakten Werte herausfinden. Der Algorithmus braucht mindestens  $\mu + 1$  und maximal  $\mu + \lambda$  Schritte um einen Zyklus zu finden. Um die exakten Werte von  $\mu$  und  $\lambda$  zu finden werden nochmals  $\mu + \lambda$  Schritte gebraucht. In jedem Schritt wird  $f$  einmal ausgewertet und es findet ein Vergleich statt.

Man vergleiche jeweils  $x_i$  mit  $x_{\ell(i)-1}$ , wobei

Definition:

$$\ell(n) := \max\{2^x \mid 2^x \leq n, x \in \mathbb{N}_0\} = 2^{\lfloor \log_2(n) \rfloor}$$

Hier testet man also für  $\mu$  exponentiell ansteigende Werte, für jedes  $\mu$  welches getestet wird probiert man dann alle  $\lambda$  von 1 bis  $\mu + 1$  aus, woraufhin man das  $\mu$  weiter erhöht. Die Zyklensuche nach Brent braucht nie mehr Schritte als die Zyklensuche nach Floyd und man erhält sofort die exakte Periodenlänge.  $\mu$  muss auch hier in einem weiteren Schritt erlangt werden. Auch dieser Algorithmus braucht mindestens  $\mu + 1$  und maximal  $\mu + \lambda$  Schritte, um einen Zyklus zu finden. Werden die exakten Werte für  $\mu$  und  $\lambda$  gebraucht, werden weitere  $\mu$  Schritte benötigt.

## Definition: Teiler

$$a \mid b \iff \exists x \in \mathbb{Z} : a \cdot x = b$$

## Definition: Primzahl

$$p \text{ ist Primzahl} \iff p \in \mathbb{P} \iff p > 1 \wedge (a \mid p \implies a = 1 \vee a = p)$$

## Definition: Kongruenz

$$a \equiv b \pmod{m} \iff m \mid (a - b)$$

## Definition: Modulo-Abbildung

$$\text{mod} : \mathbb{Z} \times \mathbb{N} \rightarrow \mathbb{Z}, \quad (a, m) \mapsto a \bmod m := a - \left\lfloor \frac{a}{m} \right\rfloor \cdot m$$

## Größter gemeinsamer Teiler

$$\text{ggT}(a, b) = \max\{d \mid (d \mid a) \wedge (d \mid b)\}$$

## Primfaktorzerlegung

Für jede natürliche Zahl  $n \in \mathbb{N}$  gibt es Primzahlen  $p_k < p_{k+1}$  und Exponenten  $\alpha_k$ , so dass:

$$n = \prod_{k=1}^M p_k^{\alpha_k}$$

# Faktorisierung nach Pollard-Rho

Sei  $f(x)$  ein Polynom mit ganzzahligen Koeffizienten und  $n$  die Zahl, die zu faktorisieren ist.

Dann gilt  $x_i = x_j \bmod n \implies f(x_i) = f(x_j) \bmod n$

Nun betrachten wir die Folgen  $(x_{a_{i+1}})_{i \geq 0} : x_{i+1} = f(x_i) \bmod a$  und  $(x_{n_{i+1}})_{i \geq 0} : x_{i+1} = f(x_i) \bmod n$  als zwei zufällige periodische Folgen, wobei  $\mu_a, \mu_n$  und  $\lambda_a, \lambda_n$  die Vorperiodenlängen bzw. Periodenlängen der Folgen sind.

Es gilt  $a \mid n$ , und daher  $\mu_a \leq \mu_n$  und  $\lambda_a \leq \lambda_n$ . Die Erwartungswerte für  $\mu_a + \lambda_a$  sowie  $\mu_n + \lambda_n$  haben wir bereits im Abschnitt über zufällige Abbildungen betrachtet.

# Faktorisierung nach Pollard-Rho

Um einen Zyklus der Folge  $(x_{a_{i+1}})_{i \geq 0}$  zu finden (Floyd oder Brent), obwohl  $a$  unbekannt ist, betrachten wir die Folge  $(x_{n_{i+1}})_{i \geq 0}$  und prüfen statt der Bedingung  $x_i = x_j$   $d := \text{ggT}(x_i - x_j, n) > 1$ .  $d$  lässt sich dann wie folgt charakterisieren:

$$d = \prod_{\substack{x_i \equiv x_j \pmod{p} \\ p|n, p \in \mathbb{P}}} p$$

Im Mittel findet man den ersten Zyklus für den kleinsten Primteiler  $p_1$  von  $n$ , wenn kein anderer Teiler von  $n$  an jener Stelle einen Zyklus hat, gilt  $d = p_1$ . Dann haben wir einen Primteiler gefunden und können den Algorithmus mit  $\frac{n}{p_1}$  erneut durchführen.

# Faktorisierung nach Pollard-Rho

Ohne  $x_0$  und/oder  $f$  abzuändern, kann kein Teiler von  $d$  gefunden werden. Insbesondere kann der Algorithmus keinen Teiler von  $n$  finden, wenn  $d = n$  gilt. Dies definiert man daher als Abbruchbedingung. Üblicherweise setzt man  $f(x) := x^2 + c$  mit  $c \neq 0, c \neq -2$ . Da die Berechnung des ggT jedoch verhältnismäßig viel Zeit ( $\log(n)$  mal Multiplikation) in Anspruch nimmt, berechnet eine optimierte Variante  $Q$  (wobei  $\log(n) \ll Q \ll n^{\frac{1}{4}}$ ) mal  $q = q \cdot (x_i - x_j)$  und dann  $\text{ggT}(q, d)$  berechnet. Dies nimmt in Kauf, dass dazwischen zu findende Teiler multipliziert werden. Um das zu verhindern kann man den alten Wert von  $x_i$  abspeichern und die Suche von dort erneut beginnen für den Fall  $d > 1$ .



Der Algorithmus scheitert genau dann, wenn  $\mu = \mu_p = \mu_n$  und  $\lambda = \lambda_p = \lambda_n$ . Die Wahrscheinlichkeit dafür ist:

$$\begin{aligned} & \sum_{\lambda=1}^p \sum_{\mu=0}^{p-\lambda} P_p(\mu, \lambda) \cdot P_n(\mu, \lambda) \\ &= \sum_{\lambda=1}^p \sum_{\mu=0}^{p-\lambda} \frac{1}{p} \prod_{k=1}^{\mu+\lambda} \left(1 - \frac{k}{p}\right) \cdot \frac{1}{n} \prod_{k=1}^{\mu+\lambda} \left(1 - \frac{k}{n}\right) \\ &= \frac{1}{n \cdot p} \sum_{\lambda=1}^p \sum_{\mu=0}^{p-\lambda} \prod_{k=1}^{\mu+\lambda} \left(1 - \frac{k}{p}\right) \cdot \left(1 - \frac{k}{n}\right) \end{aligned}$$

Der Algorithmus liefert einen Primfaktor  $p_i$  genau dann, wenn  $\mu_{p_i} + \lambda_{p_i} < \mu_{p_j} + \lambda_{p_j}$  für  $i \neq j$ . Die Wahrscheinlichkeit dafür ist:

$$\sum_{\substack{\mu_{p_i} + \lambda_{p_i} \leq p_i \\ \mu_{p_i} + \lambda_{p_i} < \mu_{p_j} + \lambda_{p_j} \leq p_j}} \prod_{j=1}^M P_{p_j}(\mu_j, \lambda_j)$$

Das Pollard-Rho verfahren ist besonders effizient für Zahlen mit einem kleinen Primfaktor. Die Zeit um einen Faktor  $p$  zu finden ist im Mittel  $\sqrt{p}$ .  $\Omega(n)$  ist die Anzahl der (mit Vielfachheit gezählten) Primfaktoren von  $n$ . Dann gilt:  $\Omega(n) \sim \log(\log(n))$  für  $n \rightarrow \infty$  (Satz von Hardy-Ramanujan). Es gilt:  $p_1 \leq n^{\frac{1}{\Omega(n)}}$ . Unter der Annahme, dass die zu faktorisierende Zahl keine Primzahl ist, ist  $\Omega(n) \geq 2$ . Dann hat man  $p_1 \leq \sqrt{n}$  als exakte Schranke.



Robert Sedgewick (1995)

An Introduction to the Analysis of Algorithms

*Addison-Wesley*



J.M. Pollard (1975)

A Monte Carlo method for factorization

*BIT Numerical Mathematics* 15(3), 331-334.



R.P. Brent (1980)

An Improved Monte Carlo Factorization Algorithm

*BIT Numerical Mathematics* 20, 176-184.



Donald E. Knuth (1997)

The Art of Computer Programming, vol. I: Fundamental Algorithms (3rd ed.)

*Addison-Wesley*



Donald E. Knuth (1997)

The Art of Computer Programming, vol. II: Seminumerical Algorithms (3rd ed.)

*Addison-Wesley*